Co nám prozradí měření ovzduší?

Kvalita ovzduší se v průběhu času mění a závisí na celé řadě okolností. Měřicí stanice nepřetržitě zaznamenávají koncentrace různých znečišťujících látek a vytvářejí tak rozsáhlé časové řady.

Vaším úkolem je využít otevřená data z měřicích stanic a pomocí metod datové analýzy nebo strojového učení **popsat, rozpoznat nebo předpovědět vývoj kvality ovzduší**.

Co můžete řešit

Můžete si vybrat například některý z následujících směrů:

- předpovědět koncentraci vybraného polutantu v následujících hodinách,
- hledat neobvyklé hodnoty nebo události v měřeních,
- porovnat chování jednotlivých měřicích stanic,
- hledat opakující se denní, týdenní nebo sezónní vzory,
- zjistit, zda se některé polutanty vyvíjejí podobně,
- vytvořit model, který rozpozná období se zhoršenou kvalitou ovzduší,
- hledat vztahy mezi kvalitou ovzduší a meteorologickými podmínkami.

Můžete pracovat pouze s daty o ovzduší nebo je kombinovat například s meteorologickými daty.

Data

K dispozici budou hodinová měření vybraných látek, například:

- PM10,
- PM2,5,
- NO_2,
- NOx,
- O_3,
- SO_2,
- případně CO.

K měřením budou k dispozici také metadata jednotlivých stanic, například:

- identifikátor a název stanice,
- poloha,
- nadmořská výška,
- typ stanice,
- charakter okolí,

- informace o měřených látkách.

Podle dostupnosti budou součástí balíčku také meteorologická data, například:

- teplota,
- vlhkost,
- tlak,
- vítr,
- srážky.

Výsledek

Výsledkem může být například:

- model předpovídající další vývoj,
- detektor anomálií,
- klasifikátor kvality ovzduší,
- vizualizace časových řad,
- interaktivní mapa,
- aplikace zobrazující aktuální stav a predikci,
- nebo jiné řešení využívající poskytnutá data.

Pokud vytváříte predikční model, rozdělte data na trénovací a testovací část tak, aby model nebyl testován na datech, která už při učení „viděl“.

Na co nezapomenout

Při prezentaci by mělo být jasné:

1. Jaký problém řešíte.
2. Jaká data a stanice jste použili.
3. Jak jste řešili chybějící nebo neplatné hodnoty.
4. Jaké proměnné jste použili jako vstupy modelu.
5. Jak jste ověřili kvalitu výsledku.
6. Co váš model umí a co už z dat určit nelze.

Cílem není pouze dosažení co nejlepší číselné metriky. Důležitá je také správná práce s časovými daty, interpretace výsledků a srozumitelná prezentace.